



پیشنهاد پروژه مطالعاتی درس استنتاج علی

A Review on Domain Adaptation in Causal Inference

علیرضا کاظمی (۹۵۱۰۵۰۳۵)

حمیدرضا منتصری (۹۵۱۰۰۲۵۳)

چکیده


مسئله تطبیق دامنه (Domain Adaptation) یکی از توانایی هایی است که می توان یک الگوریتمی که بر روی یک مجموعه داده یادگیری شده است را روی دیتای مورد نظر هدف متفاوت که البته با مجموعه دیتای قبلی ارتباط دارد را به کار گرفت. این فیلد یکی از زیرمسئله های یادگیری انتقالی (Transfer Learning) است. به صورت سنتی فرض در یک مسئله لرنینگ این است که داده ی تست و داده ی مورد یادگیری، هر دو از توزیع یکسانی می آیند اما در دنیای واقعی شاید چنین نباشد و اما ما می خواهیم بر روی دیتای تست عملکرد خوبی داشته باشیم. به طور مثال در یک مسئله کلاسیک رگرسیون اگر متغیری مدل را بهبود ببخشد، آن را وارد ویژگی های یادگیری می کنیم که در این صورت از ساختار علیت خاصی استفاده نکرده ایم. حال در اینجا بر اساس علاقه مندی به شناخت تغییرات سیستم به تناسب تغییرات محیط، با استفاده از مدل های علی که می توانند مستقل از آن تغییرات باشند، به دنبال بهبود پیش بینی هستیم. در یک مدل علی (که فقط جهت مستقیم علیت هدف را استفاده می کند) با مداخله بر روی متغیر پیش بینی کننده یا تغییر روی کل مدل، پیش بینی همچنان معتبر می ماند.

Kun Zhang, Bernhard Scholkopf, etc Domain adaptation under target and conditional shift. In Proceedings of the 30th Annual Conference on Machine Learning, 2013.

در این مقاله، مسئله انطباق دامنه را تحت سه سناریو بررسی می کند. ۱) وقتی که P_y تغییر می کند اما $P_{x|y}$ ثابت می ماند (شیفت هدف) ۲) وقتی که P_y ثابت است در حالیکه $P_{x|y}$ با قندهای مشخص تغییر می کند. (شیفت شرطی) ۳) وقتی که P_y تغییر میکند و نیز $P_{x|y}$ با قندهای مختلف تغییر می کند (شیفت تعمیم یافته هدف). حال آن ها با استفاده از دانش قبلی و بیان علیت توانسته اند وزندهی دوباره را بهبود ببخشند تا مدل بتواند در داده های تست مختلف عملکرد بهتری داشته باشد. تمرکز این مقاله بر روی سناریوی سوم که همان شیفت تعمیم یافته هدف (GeTars) است.

Sara Magliacane, Thijs van Ommen, Tom Classen, Stephan Bongers, Philip Versteeg, Joris, M.Mooji, Domain Adaptation by Using Causal Inference to Predict Invariant Conditional Distributions In Advances in Neural Information Processing Systems, 2018.

در چکیده این مقاله گفته می‌شود که هدف مسئله، پیش بینی دقیقتر هدف هنگامی که توزیع احتمال سورس های یادگیری متفاوت می‌شود، است. این تفاوت توزیع‌ها را می‌توان بر اساس محتواهای مختلف یک سیستم یکسان مدلسازی کرد. رویکرد حل مسئله در اینجا به این صورت است که با کشف ساختار علی پشت این سیستم و بدون اتکا به دانش قبلی یا نوع مداخله بتوان به نتیجه رسید. پس به طور کلی علاوه بر متغیرهای سیستم (X_i) در اینجا متغیرهای کانتکست (C_i) نیز داریم. به طور مثال در شکل زیر با مداخله بر روی متغیر C_1 که از متغیرهای کانتکست مدل است شیفت توزیع را مشاهده می‌کنیم. همانطور که مشاهده می‌شود با مداخله بر روی C_1 توزیع $P(y|X_1, C_1)$ شیفت خاصی نمی‌خورد که اما در مورد $P(y|X_3, C_1)$ صادق نیست.



Kun Zhang, Mingming Gong, Petar Stojanov, Biwei Huang, Qingsong Liu, Clark Glymour. Domain Adaptation as a problem of inference on graphical models , 2020.

در این مقاله به مسئله‌ی تطبیق دامنه‌ی نظارت نشده با رویکرد داده محور پرداخته می‌شود. یعنی در وضعیتی که ما آگاهی قبلی از نحوه‌ی تغییر توزیع مشترک در دامنه‌های مختلف نداریم. بدین منظور برای دستیابی به روشی ماشینی برای تطبیق دامنه با چندین دامنه‌ی منبع، از یک مدل گرافیکی استفاده می‌شود که به عنوان یک صورت بندی فشرده از مختصات تغییر توزیع مشترک عمل می‌کند. این مدل گرافیکی با یادگیری روی داده‌ها بدست می‌آید و پس از آن مسئله‌ی تطبیق دامنه را می‌توان به استنباط بیزی روی مدل‌های گرافیکی کاهش داد. چنین مدل گرافیکی ماژول‌های ثابت و متغیر توزیع را متمایز می‌کند و همچنین با مشخص کردن مختصات تغییر در دامنه‌ها به عنوان آگاهی پیشین از ماژول‌های متغیر هنگام استخراج توزیع پسین متغیر هدف عمل می‌کند. این مقاله در ادامه روش علیت محور تطبیق دامنه را نیز با چارچوب پیشنهادیش صورت بندی می‌کند و در انتها عملکرد چارچوب ارائه شده را روی داده‌های آزمایشگاهی و واقعی می‌سنجد.

از میان مقاله‌های ارجاع شده می‌توان از مقاله‌های زیر نیز برای گسترش دامنه تحقیق استفاده کرد:

- K. Zhang, M. Gong, and B. Schölkopf. Multi-source domain adaptation: A causal view. In Twenty-Ninth AAAI Conference on Artificial Intelligence, 2015.
- J. Kügelgen, A. Mey, and M. Loog. Semi-generative modelling: Covariate-shift adaptation with cause and effect features. In The 22nd International Conference on Artificial Intelligence and Statistics, pages 1361–1369. PMLR, 2019.
- E. Bareinboim, J. Tian, and J. Pearl. Recovering from selection bias in causal and statistical inference. In Proc. 28th AAAI Conference on Artificial Intelligence, pages 2410–2416, 2014.
- K. Zhang, B. Huang, J. Zhang, C. Glymour, and B. Schölkopf. Causal discovery from nonstationary/heterogeneous data: Skeleton estimation and orientation determination. In IJCAI, volume 2017, page 1347, 2017.
- Tian and J. Pearl. Causal discovery from changes. In Proceedings of the 17th Conference in Uncertainty in Artificial Intelligence, (UAI-01), 2001.
- J. M. Mooij, S. Magliacane, and T. Claassen. Joint causal inference from multiple contexts. arXiv.org preprint, <https://arxiv.org/abs/1611.10351v3> [cs.LG], Mar. 2018. URL <https://arxiv.org/abs/1611.10351v3>.